

FS-STBP 融合结构测试总结

一、说明

本阶段的工作基于 Optimized spiking neurons can classify images with high accuracy through temporal coding with two spikes 和 Spatio-Temporal Backpropagation for Training High-Performance Spiking Neural Networks 两篇文献，将第一篇文章的 FS 神经元模型和第二篇文章的 STBP 梯度替代算法相融合，实现了**基于 FS 神经元的直接监督学习**。

(1) K 值和 alpha 值的改进情况

原本的 FS 神经元模型每一层的 K 值和 alpha 值为定值，但是实际上，各层神经元平均发射脉冲数(平均单个神经元发的脉冲数)的分布是不均匀的。某些层数发射的脉冲数较多，某些层数发射的脉冲数较少，一般呈现出**前层多后层少**的特点。在 FS 网络中 K 值如果过大，则平均脉冲数一般会增大，从而使 SNN 芯片能耗增大。同时，由于 FS 神经元编码的误差为 $\alpha/2^K$ ，K 值过小也会导致误差的增大。

```
K = [4, 3, 3, 3, 2]
alpha = [1, 3, 4, 2, 1]

d1 = H1 = T1 = alpha[0] * 2 ** (-K[0]) * np.array([float(2 ** (K[0] -
i)) for i in range(1, K[0] + 1)]).astype(np.float32)
d2 = H2 = T2 = alpha[1] * 2 ** (-K[1]) * np.array([float(2 ** (K[1] -
i)) for i in range(1, K[1] + 1)]).astype(np.float32)
d3 = H3 = T3 = alpha[2] * 2 ** (-K[2]) * np.array([float(2 ** (K[2] -
i)) for i in range(1, K[2] + 1)]).astype(np.float32)
d4 = H4 = T4 = alpha[3] * 2 ** (-K[3]) * np.array([float(2 ** (K[3] -
i)) for i in range(1, K[3] + 1)]).astype(np.float32)
d5 = H5 = T5 = alpha[4] * 2 ** (-K[4]) * np.array([float(2 ** (K[4] -
i)) for i in range(1, K[4] + 1)]).astype(np.float32)
```

因此我对融合后的代码进行了修改，使得每一层的 K 值和 alpha 值都可以灵活调控，从而寻找更优的超参数设置方案。

(2) 脉冲发射函数的修改情况

原来的 FS 神经元代码中，每一个 step 权重都要乘 0.5（相当于 d(t)的作用）

```
self.fc1.weight.data = self.fc1.weight.data * 0.5
```

但是如果加入 STBP 算法会使反传失败，无法训练 SNN。

所以此次代码进行了修改：

```
z = act_fun(mem - th) * 0.5
```

将每个 step 的 0.5 系数补偿乘在发射函数后，反传成功，SNN 网络可以得到训练。

(3) 训练方式的改进情况

与常用的 SNN 训练方法 STDP、ANN 转化法不同的是，FS-STBP 融合结构采用的是 STBP 的反向传播方法，使用脉冲发射函数导数的近似处理函数进行梯度近似，解决了脉冲发射函数发射处不可导的问题。

```
class ActFun(torch.autograd.Function):
    '''
    Approaximation function of spike firing rate function
    '''

    @staticmethod
    def forward(ctx, input):
        ctx.save_for_backward(input)  # ctx: 类似于 self, 这里保存下来
        input 供反传用
        return input.gt(0.).float()  # input: 膜电位, gt 比较是否超过阈值
        thresh, return 脉冲 0/1
```

```

@staticmethod
def backward(ctx, grad_output):
    input, = ctx.saved_tensors
    grad_input = grad_output.clone()
    temp = abs(input) < lens# 膜电压在门限一定范围内，置1，发射脉冲，
temp 置1，该时间步的反传梯度为1
    return grad_input * temp.float()

act_fun = ActFun.apply

```

可以在不使用 ANN 进行预训练的前提下，实现 SNN 网络的直接监督学习。同时，与大多数采用 LIF-BP 算法的 SNN 相比，FS-STBP 融合结构采用的 FS 神经元具有更加优良的脉冲稀疏性和准确性，有望进一步改进 SNN 芯片性能。

二、测试结果

MLP结构: 121-64-124-64-124-10						Epoch=80					
						SNN FS-STBP结果					
alpha/K		[1, 1, 1, 1, 1]/[8, 7, 6, 5, 4]		[1, 1, 1, 1, 1]/[4, 4, 3, 2, 1]		1, 1, 0.75, 0.5, 0.25]/[4, 4, 3, 2, 1]		1, 1, 0.5, 0.5, 0.25]/[4, 4, 3, 2, 1]		[1.2, 1, 0.5, 0.5, 0.25]/[4, 4, 3, 2, 1]	
acc		96.35		96.81		96.95		96.88		96.86	
ave_spikes_1st/121-64		1.42083		0.71889		0.68621		0.69189		0.60811	
ave_spikes_2ed/64-124		0.66967		0.39054		0.39547		0.45264		0.47685	
ave_spikes_3rd/124-64		0.69528		0.34917		0.34454		0.35987		0.33601	
ave_spikes_4th/64-124		0.11507		0.07364		0.08644		0.08654		0.09057	
ave_spikes_5th/124-10		0		0		0		0		0	
alpha/K		, 0.75, 0.5, 0.5, 0.25]/[4, 3, 3, 2,		[1, 2, 2, 1, 1]/[4, 5, 5, 4, 4]		[1, 2, 3, 1, 1]/[4, 5, 6, 4, 4]		[1, 1, 2, 1, 1]/[4, 4, 5, 4, 4]		[1, 1, 2, 1, 2]/[4, 4, 5, 4, 5]	
acc		96.74		97.21		97.1		96.96		96.98	
ave_spikes_1st/121-64		0.50559		0.82659		0.84291		0.70354		0.68876	
ave_spikes_2ed/64-124		0.41834		0.54722		0.57198		0.51098		0.53501	
ave_spikes_3rd/124-64		0.34448		0.42147		0.41611		0.37637		0.50321	
ave_spikes_4th/64-124		0.08858		0.0655		0.07137		0.06272		0.06222	
ave_spikes_5th/124-10		0		0		0		0		0	
alpha/K		[1, 1, 2, 1, 1]/[3, 4, 5, 4, 3]		[1, 1, 1, 1, 1]/[4, 4, 5, 4, 4]		[1, 1, 1, 1, 1]/[4, 5, 6, 5, 4]		[1, 2, 3, 2, 1]/[4, 5, 6, 5, 4]		[1, 1.25, 1.5, 1.25, 1]/[4, 5, 6, 5, 4]	
acc		96.83		96.94		96.81		97.34		96.98	
ave_spikes_1st/121-64		0.66011		0.65485		0.86493		0.74747		0.88943	
ave_spikes_2ed/64-124		0.51814		0.53684		0.69544		0.58867		0.72808	
ave_spikes_3rd/124-64		0.47871		0.48003		0.54291		0.47204		0.52753	
ave_spikes_4th/64-124		0.0663		0.06109		0.11393		0.06605		0.13155	
ave_spikes_5th/124-10		0		0		0		0		0	
alpha/K		[1, 2, 3, 2, 1]/[3, 4, 5, 4, 3]		0.75, 1, 1.25, 1, 0.75]/[3, 4, 5, 4, 3]		[1, 2, 2, 2, 1]/[3, 4, 5, 4, 3]		[1, 3, 3, 3, 1]/[3, 4, 5, 4, 3]		[1, 3, 4, 3, 1]/[3, 4, 5, 4, 3]	
acc		96.99		96.8		96.91		96.98		97.06	
ave_spikes_1st/121-64		0.64621		0.60871		0.6198		0.54058		0.52484	
ave_spikes_2ed/64-124		0.47926		0.54905		0.57825		0.49151		0.4877	
ave_spikes_3rd/124-64		0.33317		0.4897		0.35096		0.31728		0.32821	
ave_spikes_4th/64-124		0.06262		0.06589		0.0705		0.05516		0.0658	
ave_spikes_5th/124-10		0		0		0		0		0	

alpha/K		[1, 3, 6, 2, 1]/[4, 4, 4, 3, 1]	[1, 2, 3, 2, 1]/[4, 3, 3, 3, 2]	[1, 2, 2, 2, 1]/[4, 3, 3, 3, 2]	[1, 3, 3, 2, 1]/[4, 3, 3, 3, 2]	[1,3,2,2,1]/[4,3,3,3,2]
acc		97.24	97.38	97.04	97.37	97.36
ave_spikes_1st/121-64		0.57567	0.50722	0.52828	0.44699	0.43627
ave_spikes_2ed/64-124		0.28961	0.26196	0.29765	0.27613	0.30752
ave_spikes_3rd/124-64		0.32581	0.30885	0.29728	0.29826	0.3122
ave_spikes_4th/64-124		0.08829	0.0668	0.05502	0.06339	0.06329
ave_spikes_5th/124-10		0	0	0	0	0
alpha/K		[1, 2, 2, 2, 1]/[4, 3, 3, 3, 2]	[1, 3, 4, 2, 1]/[4, 3, 3, 3, 2]	[1, 3, 4, 2, 1]/[4, 3, 3, 4, 1]	[1, 3, 4, 2, 1]/[4, 4, 3, 3, 1]	[1, 3, 4, 2, 1]/[4, 4, 4, 3, 1]
acc		97	97.28	97.17	97.37	97.38
ave_spikes_1st/121-64		0.50469	0.47745	0.45777	0.63857	0.56089
ave_spikes_2ed/64-124		0.32554	0.24289	0.22454	0.24125	0.37373
ave_spikes_3rd/124-64		0.31888	0.30288	0.4039	0.32652	0.33521
ave_spikes_4th/64-124		0.05299	0.06687	0.10406	0.09616	0.10257
ave_spikes_5th/124-10		0	0	0	0	0

每一层的 K 值和 alpha 值设置测试数据如上图。

经过测试，可以看到，第一层 K 值设为 4，后层 K 值递减；alpha 值按照“小大小”排列的训练效果较好，可以达到 **97.3%左右**。在 K 不大于 4 的情况下，通过调参可以使每层每个神经元的平均脉冲数降至 **0.5 以下**，同时还能有 97.37%左右的准确率。